長庚大學
軟硬體專題期中報告書

兒童注意力監測系統
設計文件書

（Attention Assessment System for ASD and TD Children）

指導教授:魏志達 教授
中華民國:115年4月12號
成員:劉立綸、李瑋恆、黃昱翔、黃璿軒

目錄

1.系統簡介
1.1規格目的
1.2規格範圍
1.3參考文件
2.系統概述
2.1系統目標
2.2系統範圍
2.3系統架構
2.4軟/硬體建構項目需求概述
2.5軟/硬體環境
2.6一般限制
3.設計內容
3.1軟/硬體建構項目架構
3.2軟硬體組件設計說明
3.3介面設計說明
3.4作業程序設計說明
3.5其他設計說明
4.需求追溯與版本管理

1.系統簡介

1.1規格目的

本系統主要協助研究人員進行自閉症類群障礙(Autism Spectrum Disorder, ASD)兒童與典型發展(Typical Development, TD)兒童的注意力差異評估,特別針對共同注意力(Joint Attention)中的反應性共同注意力(Responding to Joint Attention, RJA)能力進行量化分析，將於標準化測試情境中（測試物可能為氣球、泡泡、機器玩具等），以電腦機器學習技術自動判定「兒童是否將注意力聚焦於指定測試物」，並產出可供臨床參考的時間序列事件與統計指標。

本系統以 Python 為主要開發語言，結合 YOLO 物件偵測、Mediapipe關鍵點估計（手臂/手指）與視線方向估計，透過「視線向量」與「指向向量」之融合，對畫面中之目標物進行注意力判定；同時提供測試流程管理、事件標註與報表匯出功能。系統定位為臨床決策支援（CDSS）工具，目的在提升評估效率與一致性，非取代專業人員之臨床判讀或診斷決策。

研究背景及動機：
自閉症(ASD)是一種複雜的神經障礙
在眾多早期社交缺陷中，共同注意(Joint attention, JA)的發展受損，被廣泛認為是ASD最早出現、且最具預測性的核心指標之一
針對JA的精確測量，引入機器人輔助已成為重要趨勢。相較於人類測試者，機器人能提供相對一致的語氣。
結合機器人輔助評估作為自動標準化的刺激來源，以及深度學習模型作為客觀的分析系統

本規格書適用於：
1. 系統開發團隊進行系統設計與實作
2. 研究人員了解系統功能與限制
3. 測試人員進行系統驗證
4. 專案管理者進行進度管

1.2規格範圍

本文件旨在定義系統之軟體架構與模組設計，涵蓋以下技術規格範圍

- 視覺分析模組：利用MediaPipe Face Mesh檢測人臉特徵點，再利用 solvePnP 得出頭部旋轉矩陣和平移向量（頭部姿態估計），接著進行圖像正規化、神經網絡推理得出視線向量，最後將視線向量轉換出現在畫面中。
- 語音觸發模組：整合 OpenAI Whisper (large-v3) 語音辨識技術，自動擷取測試員之提示關鍵字，建立動態判定視窗。
- 邏輯判定與輸出：定義貪婪排他性綁定 (Greedy Bipartite Matching) 演算法，以及注意力/指向事件之量化紀錄與報表輸出格式。 本文件不涉及硬體

攝影機之內部電路設計，聚焦於軟體系統之功能邊界與驗收標準。

1.3參考文件

(1)技術文件:

- YOLO (You Only Look Once) 官方文件 - https://docs.ultralytics.com/
- MediaPipe 官方文件 - https://developers.google.com/mediapipe
- OpenCV 技術文件 - https://docs.opencv.org/
- Robotflow官方網頁-https://roboflow.com/universe
- OpenAI Whisper 官方技術文件 - https://github.com/openai/whisper
- ETH-XGAZE 官方技術文件 - https://github.com/xucong-zhang/ETH-XGaze
- MPIIGAZE 官方技術文件 - https://github.com/hysts/pytorch_mpiigaze_demo
- 視線估計(Gaze Estimation)論文文件- https://www.ecva.net/papers/eccv_2020/papers_ECCV/papers/123500358.pdf
- 臉部正規化(Normalization)論文文件 - https://www.collaborative-ai.org/publications/zhang18_etra.pdf

(2)研究文獻:

- Attention, joint attention相關
  - Ko, C., Lim, J.-H., Hong, J., Hong, S.-B., & Park, Y. R. (2023).*Development and validation of a joint attention–based deep learning system for detection and symptom severity assessment of autism spectrum disorder.*
  - Mundy, P., & Newell, L. (2007). *Attention, joint attention, and social cognition.*
  - Dawson, G., Toth, K., Abbott, R., Osterling, J., Munson, J., Estes, A., & Liaw, J. (2004). *Early social attention impairments in autism: Social orienting, joint attention, and attention to distress.*

- MediaPipe Framework.
  - Kothari, R. S., Yang, Z., Kanan, C., Bailey, R., Pelz, J., & Diaz, G. (2020).

Gaze-in-wild: A dataset for studying eye gaze estimation in unconstrained environments.
    - Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Uboweja, E., Hays, M., ... & Grundmann, M. (2019). *MediaPipe: A framework for building perception pipelines.*

- Eye tracking
    - Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv preprint arXiv:1805.04771.

2.系統概述

2.1系統目標

（1）主要目標：

- 量化評估：提供客觀、可重複的注意力評估數據,減少人為主觀的判斷誤差
- 數據記錄：完整記錄測驗過程中的多模態數據(影像軌跡、手勢特徵點、語音觸發時間軸)，供後續臨床與學術分析使用

2.2系統範圍

(1)功能範圍:

- 輸入端：接收研究人員拍攝之固定視角實驗研究影片(MP4)，以及預設之階段提示字卡影像檔
- 處理端：進行多模態 AI 聯合推論，包含物件追蹤、視線方向、手勢姿態之視覺辨識，以及關鍵字語音特徵之提取與分析。
- 輸出端：產生視覺化分析影片 ，並匯出包含時間戳記與注意力事件之數據報表。

（2）使用情境：

- 單一受試者測驗(一對一評估)
- 控制環境(固定測驗室設置)
- 研究人員在場操作拍攝影片與觀察

2.3系統架構

（1）資料層 (Data Layer)：影像擷取與前處理模組（物件辨識、視線追蹤、手勢辨別、語音擷取）

（2）AI推論層：應用AI模型對影像數據進行關鍵資訊的識別和提取。

（3）分析層：整合視覺與語音結果，透過貪婪排他性綁定演算法進行身分確認與碰撞判定（Ray-casting Collision），最終輸出量化指標。

2.4軟/硬體建構項目需求概述

（1）作業系統：Windows 10/11
（2）開發環境：Visual Studio Code
（3）深度學習框架：PyTorch 或 TensorFlow
（4）AI模型：YOLOv11 或以上版本、MediaPipe 0.10+、OpenAI Whisper(large-v3)

2.5軟/硬體環境

編號	軟體名稱	軟體內容與用途簡述
1	VS code	用於撰寫所需程式
2	anaconda	作為專案的標準化套件管理和環境隔離平台，確保開發、測試和生產環境的依賴套件版本保持一致。
3	OpenCV (cv2)	負責影像幀之讀取、前處理、模板匹配 (Template Matching) 及 UI 視覺化渲染。
4	Ultralytics YOLOv11	提供高 FPS 之目標物件偵測 (氣球、玩具等) 與人體姿態骨架提取 (Pose Estimation)。
5	Google MediaPipe	提供高精度之手掌與手指特徵點 (Hand Landmarks) 追蹤與幾何向量計算。
6	OpenAI Whisper	負責離線高精度音訊處理、語音轉文字及提示關鍵字時間戳記提取 (large-v3 模型)。
7	MoviePy	負責系統輸出階段之音軌安全提取與最終無聲分析影片之無縫影音縫合。

表2-1 軟體環境

編號	硬體名稱	硬體內容
1	中央處理器	AMD Ryzen™ 7 9700X
2	圖形處理器	GeForce RTX™ 5060 Ti 16GB GDDR7
3	作業系統	Windows 11 教育版
4	記憶體	DDR5 32GB

表2-2 硬體環境

2.6一般限制

- **語音收音環境限制**： 儘管系統已導入防幻覺機制與過濾參數，但若測試環境背景噪音過大（如：周圍有其他孩童哭鬧聲、尖銳的高頻雜音），或測試者與受試者發生嚴重「疊音」（同時說話），仍可能導致 Whisper 模型漏判提示關鍵字。因此，測驗應於相對安靜之獨立空間進行。
- **光源與攝影機視角限制**： 影像拍攝需維持固定視角，且受試者與測試者需大致分佈於畫面兩側。此外，測試空間需保持光線充足均勻，避免嚴重背光或陰影過暗，以免影響 YOLO 目標物偵測與 MediaPipe 膚色及特徵點擷取之成功率。
- **人員位置限制**：受測者應位於畫面中心，且距離應以1.5公尺內為限制，以便於視線估計在抓取人臉時，能夠正確捕捉到。

3.設計內容

3.1軟/硬體建構項目架構

軟體架構分層：

（1）Layer 1: 資料擷取層

- Video Capture Module：負責讀取與解析 MP4 影像串流。
- Audio Extraction Module：負責自原始影片中安全抽離純音訊軌，供先期聆聽使用。
- Frame Preprocessor：負責影像幀之色彩轉換 (BGR to RGB)、尺寸重塑與 ROI (Region of Interest) 範圍定義。
-

（2）Layer 2: AI推論層

- AudioRecognizer (OpenAI Whisper)：負責語音轉文字、過濾環境底噪，並擷取特定提示關鍵字之時間戳記。
- ObjectDetector (YOLO)：負責即時動態追蹤畫面中之氣球、泡泡機、玩具等測試物，以及人體全身骨架。
- GestureRecognizer (MediaPipe Hands)：負責高精度擷取手腕至指尖之 21 個 3D 空間特徵點。
- ETH-XGaze 預訓練之ResNet-50 模型：接收標準化後的臉部影像作為輸入，並輸出三維視線方向向量。

（3）Layer 3: 分析層

- Identity Assignment Engine：執行貪婪排他性綁定 (Greedy Bipartite Matching) 計算，確保手勢特徵準確對應至測試者或受試兒童。
- Spatial Collision Engine：計算視線向量與手指指向射線 (Ray-casting)，並判定是否與目標物之 Bounding Box 發生碰撞交集。

3.2軟硬體組件設計說明(原本是功能需求)

（1）軟體模組介紹：

模組編號	模組名稱	簡要描述 (Description)
FC-OBJ	目標物偵測	即時辨識並框出畫面中的指定測試物(如氣球、泡泡機、玩具、機器人)。
FC-GAZE	視線追蹤與判定	判斷兒童視線，判斷是否聚焦於目標物 。
FC-GEST	指向手勢辨識	偵測兒童手臂與手指之向量，並導入「貪婪排他性綁定 (Greedy Bipartite Matching)」演算法，徹底解決測試者與兒童手部交疊或距離過近時之身分誤判問題。
FC-AUDIO	語音觸發判定	採用 Whisper large-v3 模型，結合高標準靜音過濾 (no_speech_threshold=0.4)，自動擷取測試員之提

		示關鍵字，建立動態 3 秒有效判定視窗。

（2）系統架構圖：

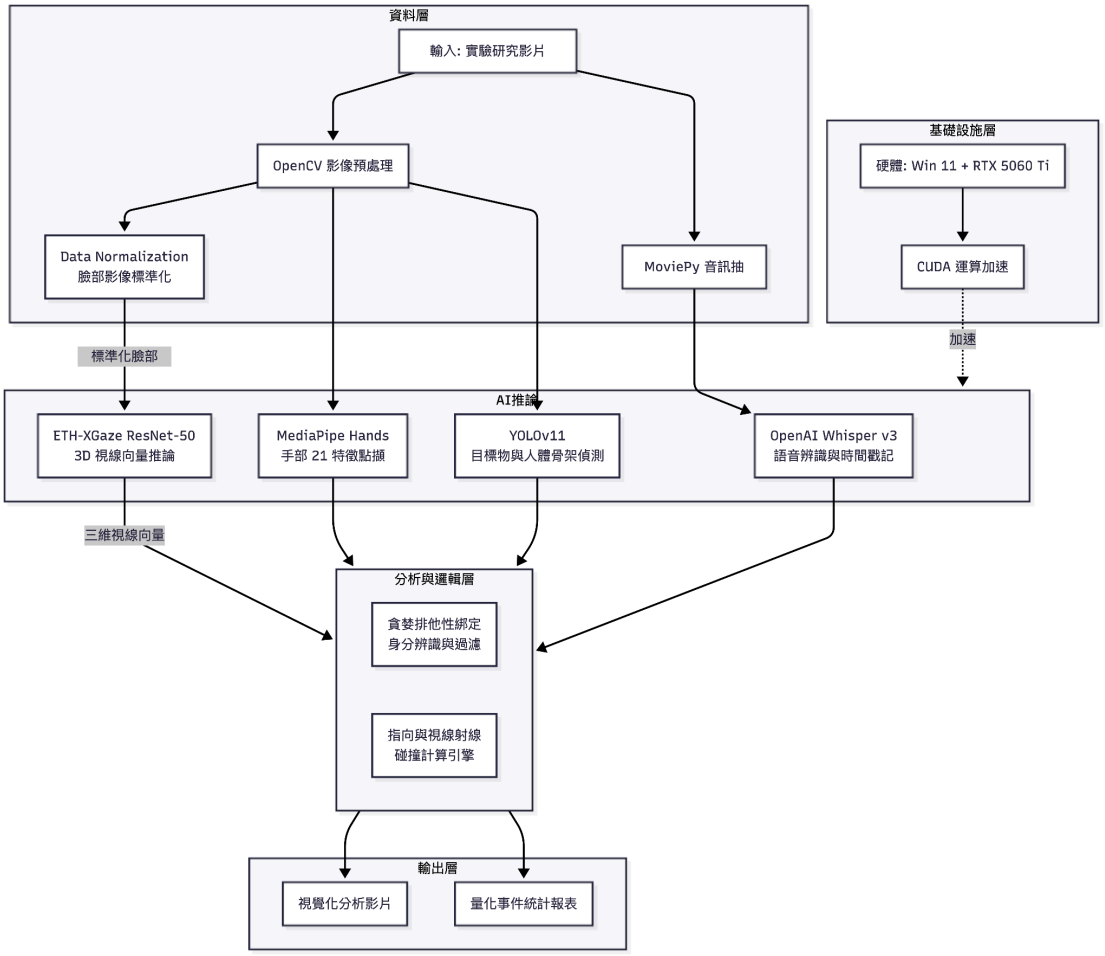

（3）資料流程圖：

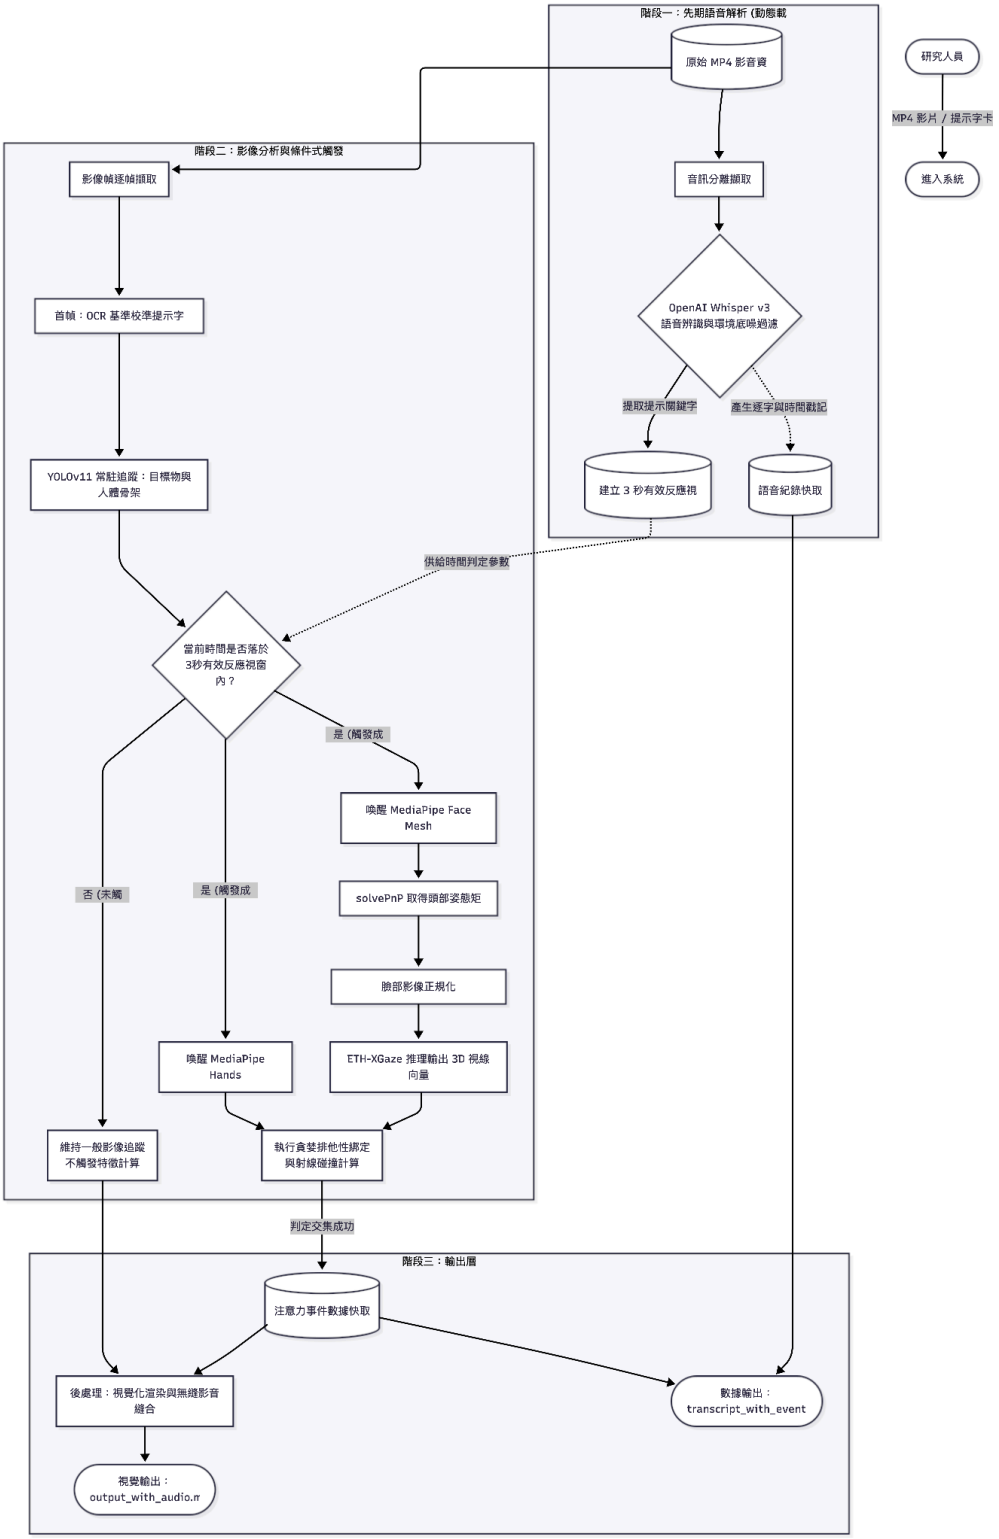

（4）各組件間的連接與運作方式：

本系統採「條件式觸發」運作：影像與語音資料首先平行輸入系統。FC-AUDIO 模組優先處理音訊並建立「觸發時間軸」。隨後，影像幀逐一輸入 FC-OBJ 模組進行常駐物件追蹤。僅當當前影像幀之時間戳記落入「語音觸發視

窗」時，系統方會喚醒 FC-GEST 模組進行手勢特徵萃取與射線碰撞計算，最終將結果匯出至分析報表。

3.3介面設計說明

(1)使用者介面(User Interface) **系統提供圖形化操作介面**(GUI), **主要包含**:

- **即時影像顯示區**：劃分左右區域，呈現模型偵測結果（目標物外框、人體骨架線條、指向射線、視線射線）。
- **狀態提示區**：螢幕左上角會顯示目前為測試階段的第幾部分，並於關鍵字觸發期間，畫面四周渲染警示框，並即時顯示「語音觸發條件成立」及當前測驗階段。
- **計分與資料區**：顯示「CHILD POINTING HIT!」得分提示與注意力事件統計。

(2)硬體介面(hardware Interface)

系統主要相容於標準 x86/x64 架構之個人電腦，依賴 NVIDIA GPU 之 CUDA 核心進行 AI 模型之硬體加速

(3)軟體介面(Software Interface)

- 系統以 Python 為主體，模組之間以函式呼叫與 JSON 格式交換資料。
- 在Visual Studio Code中，呼叫 YOLOv11與 MediaPipe 函式庫，並安裝 numpy、opencv-python、torch、torchvision（用於神經網絡推理）、matplotlib（用於可視化）套件。
- 提供無縫縫合原始音軌之 MP4 分析影片，以及純文字格式之「語音辨識逐字稿暨客觀觸發事件紀錄表 (transcript_with_events.txt)」。

3.4作業程序設計說明

(1)系統啟動 研究人員啟動系統後, 主介面會顯示即時攝影畫面與受試者資訊。

(2)測驗流程

1. **系統初始化與先期聆聽**：研究人員啟動系統，系統優先讀取影片並提取音訊，利用 Whisper 模組於背景進行全片語音解析。
2. **建立觸發視窗**：系統辨識出提示關鍵字（如：準備、看這裡），並於記憶體中建立該時間點後推 3 秒之「有效反應視窗陣列」。
3. **載入視覺核心**：語音任務安全結束後，系統載入視覺模組，釋放運算資

源並開啟影像視窗。

4. **人工校準與全幀追蹤**：使用者於首幀框選「階段提示卡」作為 OCR 基準。系統隨即展開逐幀物件偵測與階段自動推進。
5. **條件式判斷與記錄**：當影片播放至預先定義之「關鍵字觸發視窗」內，系統自動判定兒童是否有指向目標物之行為。若偵測成功，則記錄該事件（時間、目標物名稱）。
6. **後處理與匯出**：影片分析完畢後，系統自動將視覺化畫面與原始音軌進行合併，並匯出完整之語音觸發紀錄表。

(3)錯誤處理

- 若影片中未偵測到預設之語音提示關鍵字，系統將於終端機提示警告，並維持一般無條件觸發之常規影像追蹤模式，確保程式不崩潰。
- 若無法偵測到目標物，系統將不會觸發任何碰撞計分邏輯，避免無效數據產生。

3.5輸入/輸出設計說明

- **輸入設計：**
  - 靜態輸入：各測驗階段之預設提示字卡影像檔、YOLO 訓練權重檔。
  - 動態輸入：固定視角且包含清晰人聲之實驗研究影片檔 (.mp4)。
- **輸出設計：**
  - 視覺輸出：output_with_audio.mp4（包含 AI 追蹤軌跡、射線、狀態文字且具備原始音軌之最終影片）。
  - 數據輸出：transcript_with_events.txt（詳盡記錄每句語音之起訖時間，並以特殊符號去標記命中關鍵字與判定視窗之客觀紀錄表）。

3.6其他設計說明

- **模組動態載入設計 (Dynamic Loading)**： 為優化系統效能與記憶體管理，系統捨棄了開頭一次性匯入所有套件的傳統作法。採用「先期語音解析、後期載入視覺框架」的動態載入策略，此設計不僅能大幅降低程式

啟動時的記憶體峰值 (Peak Memory Usage)，亦確保了音訊處理子程序與後續龐大視覺運算管線之間的穩定性與獨立性。

4.需求制設計之追溯與版本管理

本章節記錄系統開發生命週期中各階段之需求變更與功能迭代，以作為版本管理與專案追溯之重要依據。

表 4-1 需求追溯與版本控制表

NO	修改日期	版號	修改位置	修改內容概述
1	2026.2.23	0.1	全文	擬定系統之初步邏輯架構與基礎功能需求。
2	2026.3.16	0.2	2. 系統概述 3. 設計內容	實作 Layer 2，成功整合 YOLOv11 (物件與骨架) 及 MediaPipe (手勢特徵) 雙視覺模型，確立全幀追蹤邏輯。
3	2026.3.30	0.3	3.2 組件設計 3.4 作業程序	導入「貪婪排他性綁定 (Greedy Bipartite Matching)」，徹底解決測試者與受試兒童因距離過近導致之手部身分誤判問題。
4	2026.4.13	0.4	1. 系統簡介 2. 系統架構 3. 設計內容	升級「時序分離架構」，導入 OpenAI Whisper 進行語音關鍵字觸發判定。並採用動態載入 (Dynamic Loading) 策略，優化記憶體。

附錄

附錄 A：系統訊息與日誌清單

本清單列出系統在執行階段可能於終端機或圖形化介面輸出之重要提示與狀態訊息，供研究人員與開發者參考：

- **No Object Detected**：(狀態提示)當下畫面中無法辨識到指定測試物，系統將自動暫停該幀之射線碰撞計算。
- **語音觸發條件成立：可在此執行額外判斷...**：(狀態提示)系統已偵測到提示關鍵字，畫面四周將亮起警示框，正式進入 3 秒之有效反應視窗。
- **CHILD POINTING HIT!**：(事件提示)受試兒童於有效視窗內，成功將指向射線或觸摸動作命中目標物。

附錄 B：檔案與程式模組對照表

檔案/資料夾名稱	**功能與內容說明**
project.py	系統主程式引擎，負責調度音訊提取、語音辨識、影像分析與邏輯判定。
epoch_24_ckpt.pth.tar	ETH-XGaze 裡，提供的預訓練 ResNet-50 模型是專為處理高解析度影像、跨角度視線預測而設計的深度學習骨幹網路（Backbone）。
yolov8n-pose.pt	預訓練之輕量化人體姿態與全身骨架辨識模型權重。
balloon_model.pt	客製化訓練之「氣球」物件偵測權重檔。
bubble_model.pt	客製化訓練之「泡泡」物件偵測權重檔。
toy_model.pt	客製化訓練之「玩具」物件偵測權重檔。
sample	存放各測驗階段（1~6部分）之 OCR 基準字卡圖片 (1.png ~ 6.png)。

附錄 C：輸出檔案與報表對照表

報表/檔案名稱	內容說明
output_with_audio.mp4	視覺化分析結果影片。系統將所有 AI 追蹤軌跡（手部特徵點、指向射線、目標物框線）繪製於畫面上，並於後處理階段將原始語音音軌無縫縫合之最終輸出檔。
transcript_with_events.txt	語音觸發客觀紀錄表。以純文字格式記錄實驗全期之語音轉文字稿。系統偵測到目標關鍵字時會以特殊符號標記，並精確註明專屬判定視窗（3 秒）之時間戳記，供研究人員後續進行統計與資料查核。